刘钢 (Leo)



AI 算法工程师 / 前置部署工程师 (FDE) / 大模型与边缘端落地

+86 159-9519-7640 • insistgang@163.com • 上海
GitHub: insistgang • Blog: insistgang.top • 作品集：insistgang.top/portfolio

教育背景

上海工程技术大学 硕士（电子信息 – 人工智能方向） 2024.09 — 2027.06（预计）

GPA: 3.36 / 4.0 导师: 刘翔 教授 论文方向:《面向违法建筑识别的多尺度图像检测方法研究》 荣誉: 学业奖学金一等奖、党员之星、三好学生（优秀共青团员）、团干部示范典型、活力团支部团支书

扬州大学广陵学院 学士（信息与计算科学） 2017.09 — 2021.06

GPA: 3.23 / 4.0 荣誉: 校级优秀毕业设计、中共党员（2021）

专业技能

• **AI-Native 研发与 Agent 编排**：使用 Claude Code、Codex、Antigravity、Kimi 等 AI 编程工具与 MCP；基于 LangChain / LangGraph 编排采集、分析、审核与归档，独立开发多模态视频检索平台（FastAPI / React / CLIP / SQLite FTS5）与 AI 技术知识库。

• **大模型应用与 RAG**：掌握 ReAct、Tool Use / Function Calling、Prompt 工程及多智能体工作流；实践 ChromaDB 向量检索、BM25 关键词检索与 Rerank 重排，以 FastAPI 构建 SSE 流式对话与多轮会话管理。

• **模型微调与推理优化**：实践 Qwen2-7B INT4 权重量化与 QLoRA 指令微调、Qwen2.5-VL 多模态微调；掌握 PyTorch → ONNX → TensorRT FP16 / INT8 编译与算子融合，具备消费级 GPU 单卡离线推理及 Jetson Orin Nano 端侧部署经验。

• **计算机视觉与工程实现**：熟悉 YOLOv8 / YOLOv11-seg 目标检测与实例分割，实践高分辨率浅层感知、DySample 上采样与遥感跨域迁移；掌握 OpenCV、相机标定、单目测距与视频流推理。

实习经历与核心项目

上海卓繁信息 · 政企智能 Agent 与政策 RAG | 行业市场部 2026.09 — 至今

后端开发工程师（AI 应用开发实习） [技术栈: ReAct / Function Calling / ChromaDB / BM25 / Rerank / FastAPI / SSE]

• 面向政企政策咨询、事项检索与材料预审，参与智能体工作流研发；基于 ReAct 组织意图识别与任务拆解路由，用 Tool Use / Function Calling 对接事项库检索与业务接口。
• 参与政策知识 RAG 检索链路开发，结合 ChromaDB 向量检索、BM25 关键词检索与 Rerank 重排，为领域问答组织相关政策依据。
• 基于 FastAPI 开发 SSE 流式对话接口与多轮会话管理，补充超时重试与结构化输出校验。

上海五零盛同 · 道路智能检测与单目测距系统 | 中国电科五十所 · 算法实习 2025.10 — 2026.07

算法研发实习生；负责检测模型、测距算法与时域稳定性优化 [技术栈: YOLOv8 / OpenCV / 相机标定 / 单目测距 / Kalman 滤波 / 车载工控机]

• 针对道路巡检中的细长杆状目标、逆光与遮挡，改进 YOLOv8 检测模型，在自建数据集上实现 mAP50 92.4%；结合相机内参几何标定与检测框底边像素定位设计单目测距算法，5–50 m 范围内相对误差 <5%。
• 引入 Kalman 滤波与时域平滑抑制车载抖动和距离跳变，完成算法在实车工控机上的部署与联调，应用于实际生产巡检；协同开展道路裂缝、坑槽检测的前期预研与数据构建。

多智能体协同网络安全威胁智能分析系统 | “华为杯”网安创新大赛 · 国家三等奖 2025.07 — 2025.10

队长；负责量化、微调、核心架构与工作流，队员负责日志清洗和前端 [技术栈: Qwen2-7B / INT4 / QLoRA / Multi-Agent / ChromaDB / ATT&CK]

• 负责 Qwen2-7B INT4 权重量化与 QLoRA 领域微调，将显存由 14 GB 压缩至 5.8 GB，单张消费级 GPU 达 42 tokens/s，实现安全敏感场景的内网离线推理。
• 设计日志解析、知识检索、攻击链推理、报告生成四层 Agent 研判工作流，接入 ChromaDB 8 万+ ATT&CK 情报条目；整体威胁研判准确率较单模型直接生成提升 12%，团队获国家三等奖。

硕士课题 · 遥感违建检测与 Jetson 边缘推理部署 | 上海工程技术大学 2024.10 — 至今（在研）

课题负责人；独立负责数据构建、模型改进、实验与端侧部署 [技术栈: YOLOv11s-seg / DySample / TensorRT / Jetson Orin Nano]

• 面向无人机航拍中的微小违建目标与复杂地形，构建 1,752 张高分辨率实测图像数据集；基于 YOLOv11s-seg 引入高分辨率浅层感知与 DySample 动态上采样，小目标违建分割 mAP50 提升 3.8%。
• 完成 PyTorch → ONNX → TensorRT 编译、量化与算子融合，Jetson Orin Nano 显存占用降低 60%，视频流推理维持 45+ FPS；并完成无人机视频拉流与图斑坐标反算的系统联调。

竞赛荣誉与学术成果

• 【国家级竞赛】“华为杯”第二十二届中国研究生数学建模竞赛国家二等奖（队长）；“华为杯”第七届中国研究生人工智能创新大赛国家三等奖（队长·智研四象）；“华为杯”第四届中国研究生网络安全创新大赛国家三等奖（队长·AI 盾卫队）；2025 中国研究生创“芯”大赛·EDA 精英挑战赛国家三等奖。

• 【其他竞赛】2025 第十九届 CIMC“西门子杯”中国智能制造挑战赛华北二赛区一等奖；第七届上海市研究生智慧城市创意设计大赛暨长三角第五届研究生智慧城市创意设计大赛三等奖；2025 第三届上海市大学生行业分析大赛银奖；2024 第二届上海市大学生行业分析大赛三等奖；第二十届中国研究生电子设计竞赛上海赛区团队三等奖（2025，智能追光式输电线路在线监测装置）。

• 【能力认证】CCF 大模型能力认证（LMCC-A）成人组一级认证（2026-09-19，中国计算机学会）。

• 【软件著作权】研发费用智能核算与报表自动化 RPA 软件 V1.0（登记完成，独立开发）。